

Klassificering av handskrivna siffror med *Logistic Regression* och *Random Forest* på MNIST-datasetet



Marius Savin
EC Utbildning
Rapport Machine Learning
2025-06

Abstract

This report compares Logistic Regression and Random Forest for classification of handwritten digits using the MNIST dataset. The models are evaluated with cross-validation, validation set and final test set. Random Forest achieves the highest accuracy on the validation and test set.

Innehållsförteckning

Abstract	2
1 Inledning	1
2 Teori	2
3 Metod.....	3
3.1 Datakälla och förberedelse.....	3
3.2 Modellträning och utvärdering	3
4 Resultat och Diskussion	4
5 Slutsatser	5
6 Teoretiska frågor	6
7 Självutvärdering.....	8
Appendix A	9
Källförteckning	10

1 Inledning

Klassificering av handskrivna siffror är en grundläggande uppgift inom maskininlärning, ofta löst med hjälp av MNIST-datasetet. Syftet med denna rapport är att undersöka hur väl modellerna "Logistic Regression" och "Random Forest" kan klassificera handskrivna siffror, samt att jämföra deras prestanda.

- Hur kan man klassificera handskrivna siffror med hjälp av maskininlärning?
- Vilken av modellerna "Logistic Regression" eller "Random Forest" presterar bäst på MNIST-datasetet.

2 Teori

Maskininlärning för klassificering innebär att en modell tränas att förutsäga vilken kategori en indata tillhör (Géron, 2019, s. 85). "Logistic Regression" är en linjär modell som ofta fungerar bra för enklare klassificeringsuppgifter. "Random Forest" är en ensemblemetod som kombinerar flera beslutsträd och tenderar att prestera särskilt bra på komplexa och högdimensionella data (Géron, 2019, s.197).

För att utvärdera modeller används metrik som **accuracy**, **precision**, **recall** och **f1-score**. En "Confusion Matrix" ger också insikt i modellens styrkor och svagheter.

3 Metod

3.1 Datakälla och förberedelse

MNIST-datasetet laddades via *scikit-learn*. Data delades upp i tränings, validerings och testmängder. Eftersom "Logistic Regression" kräver normaliserade värden för att träningen ska konvergera, användes *StandardScaler* för skalning av data.

3.2 Modellträning och utvärdering

Både modellerna tränades på träningsdatan. "Cross-validation" användes för att mäta prestanda robust, följt av utvärdering på valideringsdatan. Slutligen utvärderades den bästa modellens prestanda på testdatan. Den modell med högst valideringsnoggrannhet valdes för slutlig testning.

4 Resultat och Diskussion


Resultaten visar att båda modellerna presterar väldigt bra men "Random Forest" uppnår högre noggrannhet på valideringsdatan och väljs därför som slutlig modell.

Model	CV Accuracy	Validation Accuracy	Test Accuracy
Logistic Regression	0.91	0.92	0.97
Random Forest	0.96	0.97	0.97

Tabell 1: Visar resultatet från utvärderingen.

"Random Forest" (Tabell 1) når högst noggrannhet på både validerings och testdatan, och har även högre *precision* och *recall* över de flesta klasser.

"Confusion Matrix" (Figur 1) visar att vissa siffror *till exempel 5 och 3* förväxlas ibland men överlag fungerar modellen väldigt bra på hela datasettet.



Figur 1: Confusion Matrix för Random Forest modellen på testdatan.

Resultaten överensstämmer med tidigare forskning (Géron, 2019) där "Random Forest" ofta ger bättre resultat på komplexa och stora dataset jämfört med enklare linjära modeller.

5 Slutsatser

Både "Logistic Regression" och "Random Forest" fungerar bra för klassificering av handskrivna siffror på MNIST-datasetet. "Random Forest" presterar bäst och rekommenderas som slutlig modell. Arbetet visar vikten av att testa flera modeller och använda korrekta utvärderingsmetoder enligt bästa praxis inom maskininlärning (Géron, 2019).

6 Teoretiska frågor

1. **Träningsdata:** Används för att träna maskinlärningsmodellen.
Valideringsdata: Den används för att justera hyperparametrar och kunna välja bästa modell, utan att påverka testresultatet.
Testdata: Används endast för slutlig utvärdering av den valda modellen för att kunna uppskatta modellens generaliseringsförmåga på nytt.
2. Julia bör använda cross-validation (till exempel k-faldig korsvalidering) på träningsdata för att kunna jämföra modellerna. Detta innebär att varje modell tränas och utvärderas flera gånger på olika uppdelningar av träningsdatan. Modellen med bäst genomsnittligt resultat väljs.
3. Ett "regressionsproblem" innebär att man försöker förutsäga ett kontinuerligt numeriskt värde (till skillnad från en klass till exempel).

Några exempel på modeller är:

- Linjär Regression
- Lasso Regression
- Ridge Regression
- Random Forest Regressor
- Neurala Nätverk

Några användningsområden:

- Förutsäga Bostadspriser
- Prognostisera Försäljning
- Förutsäga Aktiekurser

4. RMSE (Root Mean Square Error) är ett mått på hur mycket modellens förutsägelser i genomsnitt avviker från de faktiska värdena. Till exempel ett lägre RMSE innebär att modellen gör mindre fel. RMSE används också för att utvärdera och jämföra regressionsmodeller.
5. Ett "klassificeringsproblem" är när målet är att förutsäga en kategori eller klass som till exempel "spam" eller inte "spam".

Några exempel på modeller:

- Support Vector Machine (SVM)
- Random Forest Classifier
- Neurala Nätverk för klassificering

Några användningsområden:

- E-postspamfiltrering
- Medicinsk diagnos (frisk/sjuk)

"Confusion Matrix" är en tabell som visar antal rätt och felaktiga förutsägelser för varje klass vilket hjälper till att analysera modellens prestanda särskilt vid "multiclass problems".

6. K-means "unsupervised" klustringsalgoritm som grupperar data i k – kluster, så att objekt i samma kluster liknar varandra mer än objekt i andra kluster.
Den kan användas i kundsegmentering som till exempel gruppera kunder baserat på köpbeteende.

7. Ordinal Encoding tilldelar unika heltal till kategorier.

- Exempel {låg=1, mellan=2, hög=3}

One-Hot Encoding skapar en binär kolumn per kategori.

- Exempel {röd, grön, blå} → [1,0,0], [0,1,0], [0,0,1]

Dummy Variable Encoding är som en one-hot men en kolumn tas bort för att undvika överflöd.

- Exempel: För {röd, grön, blå} används bara två kolumner till exempel [1,0], [0,1], [0,0].

8. I detta fallet så har Julia rätt eftersom att om datan är ordinal eller nominal beror på kontext och tolkning. Färger är vanligtvis nominala (ingen ordning), men om en ordning definieras till exempel ("röd är bäst") blir de ordinala i det sammanhanget.

9. Streamlit är ett öppet Python-bibliotek för att snabbt och enkelt skapa interaktiva webbappar, särskilt för till exempel dataanalys och maskininlärning. Man kan använda det för att bygga dashboards, visualiseringsvtyg eller demo-appar för ML-modeller med minimal kod.

7 Självutvärdering

1. En utmaning jag har haft var att förstå och hantera felmeddelanden i Jupyter Notebook, särskilt när variabler inte var definierade eller när plotten av "Confusion Matrix" inte fungerade direkt. Jag löste detta genom att läsa felmeddelanden noggrant samt testa olika kodsnittar och köra cellerna i rätt ordning. Det hjälpte mig att lära mig mer om felsökning och maskininlärning i praktiken.
2. Jag anser att jag ska ha betyget G för att jag har uppnått betygsriterierna som krävs. Jag har besvarat dem teoretiska frågorna, modellerat MNIST data med minst två olika modeller samt skrivit rapporten.

Appendix A

Final Test Accuracy: 0.9689				
	precision	recall	f1-score	support
0	0.97	0.99	0.98	980
1	0.99	0.99	0.99	1135
2	0.96	0.97	0.96	1032
3	0.96	0.96	0.96	1010
4	0.97	0.97	0.97	982
5	0.98	0.96	0.97	892
6	0.97	0.98	0.98	958
7	0.97	0.96	0.97	1028
8	0.96	0.95	0.96	974
9	0.96	0.95	0.95	1009
accuracy			0.97	10000
macro avg	0.97	0.97	0.97	10000
weighted avg	0.97	0.97	0.97	10000

Figur 1: Fullständig klassificeringsrapport för "Random Forest" på testdatan.

Källförteckning

Géron, A (2019). *Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow* (2nd edition). O'Reilly Media.